

Documentación del trabajo practico

Artificial Intelligence Foundations - Fundacio URV
Reto: ML clásico - Predicción de precios de vivienda
Equipo: Adrià y Raúl

Abstract (máximo 150 palabras; actual: 98)

Este trabajo implementa un pipeline de aprendizaje supervisado para estimar el precio de venta de viviendas a partir de datos tabulares. Se formula como problema de regresión con métrica principal RMSE. Se utiliza el conjunto publico House Prices de Kaggle (1460 registros) y scikit-learn con RandomForestRegressor. Se realiza exploración de datos, preprocesamiento, entrenamiento de un modelo baseline, evaluación con RMSE, MAE y R2, y búsqueda de hiperparámetros. La demostración se presenta mediante una aplicación Streamlit que permite introducir características de la vivienda y obtener una predicción orientativa. Se concluye con reflexión sobre limitaciones del modelo y mejoras futuras.

Introducción

La fijación de precios inmobiliarios depende de múltiples factores y suele requerir comparativas manuales. El machine learning permite automatizar estimaciones a partir de datos históricos, con aplicaciones en tasación orientativa y apoyo a la decisión. Este proyecto desarrolla un pipeline completo desde la definición del problema hasta una demo usable.

Formulación del problema

Tipo de aprendizaje: supervisado (cada ejemplo tiene etiqueta de precio real).
Tarea: regresión (variable objetivo continua: SalePrice).
Métrica principal de éxito: RMSE (error cuadrático medio en raíz, en unidades de precio).
Otras métricas: MAE y coeficiente de determinación R2.
Objetivo: minimizar el error de predicción en conjunto de prueba manteniendo un modelo interpretable.

Recopilación de datos

Fuente: Kaggle - House Prices: Advanced Regression Techniques.
Archivo: train.csv con 1460 filas y 81 columnas (incluye SalePrice).
Requisito URV: el dataset supera el mínimo de 500 registros exigido para retos de ML clásico.


Muestra de 5 filas del dataset (1460 filas, 81 columnas):

	Id	MSSubClass	MSZoning	LotFrontage	LotArea	Street	Alley	LotShape	LandContour	Utilities	...	PoolArea	PoolQC	Fence	MiscFeature	MiscVal	MoSold	YrSold	SaleType	SaleCondition	SalePrice
0	1	60	RL	65.0	8450	Pave	NaN	Reg	Lvl	AllPub	...	0	NaN	NaN	NaN	0	2	2008	WD	Normal	208500
1	2	20	RL	80.0	9600	Pave	NaN	Reg	Lvl	AllPub	...	0	NaN	NaN	NaN	0	5	2007	WD	Normal	181500
2	3	60	RL	68.0	11250	Pave	NaN	IR1	Lvl	AllPub	...	0	NaN	NaN	NaN	0	9	2008	WD	Normal	223500
3	4	70	RL	60.0	9550	Pave	NaN	IR1	Lvl	AllPub	...	0	NaN	NaN	NaN	0	2	2006	WD	Abnorml	140000
4	5	60	RL	84.0	14260	Pave	NaN	IR1	Lvl	AllPub	...	0	NaN	NaN	NaN	0	12	2008	WD	Normal	250000

Evaluación de los datos


Se explora la estructura del conjunto, la distribución de SalePrice, valores faltantes, correlaciones entre variables numéricas y posibles valores atípicos (por ejemplo superficie habitable frente a precio).

Histograma con la distribución del precio de venta:




Media SalePrice: 180921.2
Mediana SalePrice: 163000.0

Mapa de calor de las variables más relacionadas con SalePrice:



Outliers visuales:



Ingeniería de características

Para el modelo desplegado en la aplicación se utilizan seis variables numéricas con imputación de mediana dentro del pipeline de scikit-learn:

- OverallQual (calidad materiales)
- GrLivArea (superficie habitable)
- GarageCars (capacidad del garaje)
- TotalBsmtSF (superficie total del sótano)
- FullBath (número baños completos)
- YearBuilt (año de construcción)

El notebook notebooks/02_preprocessing.ipynb documenta un preprocesamiento mas amplio (numéricas y categóricas). En Streamlit las superficies se introducen en m2 y se convierten internamente a pies cuadrados.

Entrenamiento del modelo

Se entrena un RandomForestRegressor como modelo baseline. El valor de las variables obtenidas en el baseline es el siguiente.

	version	rmse	mae	r2
0	baseline_random_forest	29102.2567	19067.1761	0.8896

El entrenamiento reproducible esta en src/train.py y en notebooks/03_modeling.ipynb.

Ajuste de hiperparámetros

Se aplica RandomizedSearchCV con validación cruzada (ver notebooks/04_tuning.ipynb). Se compara RMSE (y MAE, R2) del baseline frente al mejor conjunto encontrado. En la ejecución registrada el modelo ajustado no mejora al baseline en test; se documenta explícitamente.

Evaluación del modelo (versión final)

Resultados en conjunto de prueba (división 80/20, random_state=42). Se considera versión final operativa en la aplicación el baseline, por obtener mejores métricas en test que la variante ajustada en 04_tuning.ipynb.

Tabla comparativa de los valores de las variables baseline vs tuning:

	version	rmse	mae	r2
0	baseline_random_forest	29102.2567	19067.1761	0.8896
1	tuned_random_forest	29723.6926	19330.8601	0.8848

Conclusión

Se ha completado un pipeline de ML clásico desde datos hasta demo en Streamlit, con métricas objetivas y comparativa baseline frente a tuning. La herramienta es orientativa y no sustituye una tasación profesional. Líneas futuras: mas variables, modelos alternativos y mayor explicabilidad.