



House Price Prediction

Proyecto de Machine Learning

Artificial Intelligence Foundations — Fundació URV

Adrià · Raul | Mayo 2026



¿Qué queríamos conseguir?

El problema

Predecir el precio de una casa (SalePrice)
a partir de sus características
(tamaño, calidad, ubicación...)

El dataset

Kaggle House Prices
1.460 casas · 80 variables
Datos reales de Ames, Iowa

El enfoque


Pipeline completo de ML:
EDA → Preprocesamiento → Modelo → App

El resultado

App interactiva en Streamlit
donde puedes meter datos
y obtener una predicción




Explorando los datos (Exploratory Data Analysis)




Precios de las casas

Mayoría entre 100k y 200k
Distribución asimétrica
(la mayoría son casas asequibles)



¿Qué afecta al precio?

OverallQual (0.79) ← calidad
GrLivArea (0.71) ← metros
GarageCars (0.64) ← garaje



Valores faltantes

Hay columnas con muchos valores vacíos, como PoolQC (99.5%) o MiscFeature (96.3%)



Aprendizaje:

No todas las variables son importantes. Nos podemos centrar en las que más se relacionan con el precio.



Limpieza y preparación de los datos

Rellenar huecos

Valores vacíos:

- Números → mediana
- Categorías → moda

Estandarizar

Poner todos los números en la misma escala con StandardScaler

Convertir texto a números

Categorías → OneHotEncoding
(cada opción se vuelve una columna de 0/1)



División del dataset:

80% Train

1.168 casas
para entrenar

20% Test

292 casas
para evaluar

¿Por qué separar?

Si evaluamos con los mismos datos que usamos para entrenar, el modelo haría "trampa" y no sabríamos si funciona de verdad con casos nuevos.

★ Las 6 variables más importantes

Nos quedamos con las que más influyen en el precio. Así el modelo es más sencillo de entender.

OverallQual

0.79

Calidad de la casa

GrLivArea

0.71

Metros cuadrados habitables

GarageCars

0.64

Plazas de garaje

TotalBsmtSF

0.61

Tamaño del sótano


FullBath

0.56

Baños completos



Con solo 6 variables podemos predecir el precio con bastante precisión. Menos es más.



Nuestro primer modelo

Empezamos con un modelo sencillo: Random Forest — sin ajustar, con los valores por defecto.



Configuración

Algoritmo: RandomForestRegressor

300 árboles de decisión

Entrenado con las 6 variables



Resultados en test

RMSE

\$29.102

Error típico (en \$)

MAE

\$19.067

Error absoluto medio

R^2

0.8896

Precisión (1 = perfecto)



¿Qué significa $R^2 = 0.89$?

El modelo explica el 89% de la variación de los precios. Dicho de otro modo: de cada 10 casas, el modelo acierta la tendencia de casi 9.

El error típico es de unos \$29.000 — para ser nuestro primer modelo con solo 6 variables, ¡no está nada mal!



Intentando mejorar el modelo

Probamos a ajustar los parámetros del Random Forest para ver si podemos mejorarlo.



Cómo lo hicimos

- RandomizedSearchCV: prueba 25 combinaciones de 432 posibles
- 3 validaciones cruzadas cada una → 75 entrenamientos en total
- Parámetros usados: profundidad, número de árboles, muestras mínimas, etc.



Resultados

RMSE: \$29.724 (antes \$29.102)

MAE: \$19.331 (antes \$19.067)

R²: 0.8848 (antes 0.8896)



El modelo por defecto funcionó mejor



¿Qué aprendimos?

No siempre hace falta complicarse. El modelo por defecto ya era muy bueno. A veces, con lo básico bien hecho, se consiguen resultados excelentes.



Comparativa: Baseline vs Tuned

Métrica	Baseline	Tuned	¿Mejóro?
RMSE	\$29.102	\$29.724	✗ No
MAE	\$19.067	\$19.331	✗ No
R ²	0.8896	0.8848	✗ No

El modelo baseline con valores por defecto es suficiente y más robusto

Conclusión

Para este proyecto, con lo básico bien hecho obtenemos un resultado sólido.
En el futuro podríamos probar otros modelos (XGBoost, Gradient Boosting) para intentar mejorarlo.



La app en Streamlit



Predictor de precios de vivienda

Aplicación desarrollada para AI Foundations — Fundació URV

Comparativa entre RandomForestRegressor baseline y modelo con tuning de hiperparámetros.

Introduce las características de la vivienda

Calidad general (OverallQual)



Superficie habitable (m²)

140,00

Capacidad del garaje (GarageCars)



Pruébalo tú mismo

Mueve los deslizadores de calidad, metros cuadrados, garaje... y el precio se actualiza automáticamente. Así de fácil.

Fork



Características

Interfaz sencilla e intuitiva
Ajusta las 6 variables clave
Predicción al instante
Sin instalar nada en tu PC



Acceso

Disponible online en:
house-prices-v3nrejcyjltydctev9hgk.streamlit.app



El pipeline completo



EDA

Análisis de los datos




Limpieza

Rellenar huecos y estandarizar



Selección

Elegir las 6 mejores



Modelo

Random Forest entrenado






App

Predicción interactiva



Así se ven los datos en cada etapa:



Predictor de precios de vivienda

Aplicación desarrollada para la Fundación URV
Comparativa entre Random Forest y regresión lineal y modelo con testing de hiperparámetros.

Introduce las características de la vivienda

Calidad general (OverallQual)

Superficie habitable (sqft)

Capacidad del garaje (GarageCars)

Superficie sótano (sqft)

Baños completos (FullBath)

Año de construcción (YearBuilt)



Qué aprendimos con este proyecto

✓ **R² de 0.89**

Con solo 6 variables nuestro modelo acierta el 89% de la variación de precios

✓ **Pipeline completo**

Aprendimos a hacer todo el proceso: desde los datos hasta una app funcionando

✓ **Un buen preprocesado marca la diferencia**

Entender, limpiar y seleccionar los datos es tan importante como el modelo

✓ **La simplicidad también funciona**

A veces el modelo inicial ya es suficientemente bueno: más complejidad no siempre significa mejores resultados



Próximos pasos

Probar XGBoost, Gradient Boosting, más variables, log-transform...



¡Gracias!



Repositorio

github.com/Racap/house-prices



App Streamlit

house-prices-v3nrejcyjlttdctev9hgk.streamlit.app



Vídeo demostración

youtu.be/KWWt_EOOM8A



Documentación técnica

[doc.pdf](#)

¿Preguntas? 😊